# covid19-modificat

January 27, 2021

```
[1]: from os import path
import pandas as pd
import numpy as np
```

## 0.0.1 Predictia evolutiei starii pandemiei de Covid19

Se incearca rezolvarea problemei predictiei (Forecasting) a evolutiei numarului de cazuri de la o zi la alta pe o anumita perioada de timp. In urma predictiilor se va prezice daca pandemia se va termina repede/lent si daca se va termina curand in lume sau intr-o anumita tara (gen Romania).

In urmatoarele momente se va prezenta structura bazei de date (a dataset-ului/csv-ului) respectiv cea a datelor locale din punct de vedere statistic. Setul de date a fost descarcat de pe Kaggle de la aceasta adresa: https://www.kaggle.com/sudalairajkumar/novel-corona-virus-2019-dataset.

Acesta contine mai multe fisiere, unul generalist si cinci dintre ele puse pe serii de timp. Se va folosii doar fisierul cu seriile de timp globale ale numarului de cazuri confirmate.

Campurile setului de date sunt: provincia (poate sa lipseasca), tara, coordonatele geografice (nu se vor folosii) si numarul de cazuri de la 22 Ian 2020 pana la 6 Dec 2020 (la momentul actual).

### 0.0.2 Incarcare set de date si afisarea unor date statistice ale setului de date

```
[2]: locatie = path.join(path.curdir, 'kaggle', 'covid19', 'input')
locatie_csv = path.join(locatie, 'time_series_covid_19_confirmed.csv')
```

## 0.0.3 Se afiseaza setul de date complet

S-a renuntat la coordonatele geografice si s-a indexat dupa provincie si tara. Provincia care nu este mentionata (camp null) a fost inlocuit cu 'Unknown' si s-au afisat primele 8 tari.

```
[3]: time_series_csv = pd.read_csv(locatie_csv, na_values=['?', 'na', 'nan', 'NaN'])
time_series_csv['Province/State'] = time_series_csv['Province/State'].

→fillna('Unknown')
time_series_csv.set_index(['Province/State', 'Country/Region'], drop=True,

→inplace=True)
time_series_csv.drop(labels=['Lat', 'Long'], axis=1, inplace=True)
time_series_csv.head(8)
```

[3]: 1/22/20 1/23/20 1/24/20 1/25/20 \

Province/State Country/Region

Unknown	Afghanistan	0	0	0	0	
	Albania	0	0	0	0	
	Algeria	0	0	0	0	
	Andorra	0	0	0	0	
	Angola	0	0	0	0	
	Antigua and Barbuda	0	0	0	0	
	Argentina	0	0	0	0	
	Armenia	0	0	0	0	
		1/26/20	1/27/20	1/28/20	1/29/20 \	
	Country/Region	•	^	•	•	
Unknown	Afghanistan	0	0	0	0	
	Albania	0	0	0	0	
	Algeria Andorra	0	0	0	0 0	
	Angola	0	0	0	0	
	Antigua and Barbuda	0	0	0	0	
	Argentina	0	0	0	0	
	Armenia	0	0	0	0	
		1/30/20	1/31/20	11/27/	20 11/28/20	\
	Country/Region		•		45044	
Unknown	Afghanistan	0	0	457		
	Albania	0	^	362 801		
	Algeria Andorra	0	^		10 6610	
	Angola	0	^	150		
	Antigua and Barbuda	0	0		41 141	
	Argentina	0	0	14072		
	Armenia	0	•	1323		
		11/29/20	11/30/20	12/1/20	12/2/20 \	
Province/State	Country/Region					
Unknown	Afghanistan	46116	46274	46516	46718	
	Albania	37625	38182	39014	39719	
	Algeria	82221	83199	84152	85084	
	Andorra	6712	6745	6790	6842	
	Angola	15103	15139	15251	15319	
	Antigua and Barbuda	141	141	142	144	
	Argentina	1418807				
	Armenia	134768	135124	135967	137231	
Drawings/State	Country /Domina	12/3/20	12/4/20	12/5/20	12/6/20	
Province/State Unknown	• •	46837	46837	47072	47306	
	Afghanistan Albania	40501	41302	47072 42148	47306 42988	
	Algeria	40301 85927	86730	87502	42900 88252	
	801 10	30321	50100	01002	00202	

Andorra	6904	6955	7005	7050
Angola	15361	15493	15536	15591
Antigua and Barbuda	144	144	144	144
Argentina	1447732	1454631	1459832	1463110
Armenia	138508	139692	140959	141937

[8 rows x 320 columns]

### 0.0.4 Intervalele valorilor numerice din setul de date (se afiseaza)

- cate date se cunosc in Romania (aprox 300 de zile)
- media statistica a intregului set de date (in medie 85000 de cazuri sunt confirmate in raport cu perioada)
- abaterea standard de la medie a datelor (in caz de exista o distributie normala a datelor)
- valoarea minima (este 0 deoarece datele sunt corecte si nu pot exista minus numar de cazuri)
- valoarea maxima (este ~500000 de cazuri sunt confirmate la ora actuala in total)

De mentionat: Datele din set sunt in timp, un numar reprezinta numarul de cazuri total in ziua respectiva

```
[4]: romania = time_series_csv.loc[('Unknown', 'Romania'),]
romania.index = pd.to_datetime(romania.index)
```

```
[5]: romania.describe()
```

```
[5]: count
                  320.000000
               85229.384375
    mean
              123010.469569
     std
    min
                    0.000000
     25%
                5859.250000
     50%
               26776.000000
     75%
              109071.750000
              513576.000000
    max
    Name: (Unknown, Romania), dtype: float64
```

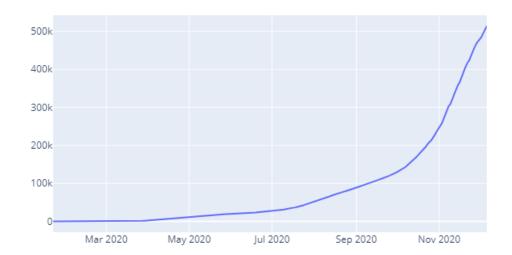
## 0.1 Evolutia numarului total de cazuri in Romania

 $^{**}$ Graficul de mai jos prezinta evolutia in timp, continua, a numarului total de cazuri din Romania  $^{**}$ 

!pip install plotly !pip install psutil !conda install -y -c plotly plotly-orca

```
[6]: from plotly.graph_objs import Scatter, Figure
   import plotly.io as pio
   pio.renderers.default = 'png'
   splot = Figure()
   splot.add_trace(Scatter(x=romania.index, y=romania, name='confirmate'))
   splot.update_layout(title='Cazuri in Romania')
   splot.show()
```

### Cazuri in Romania

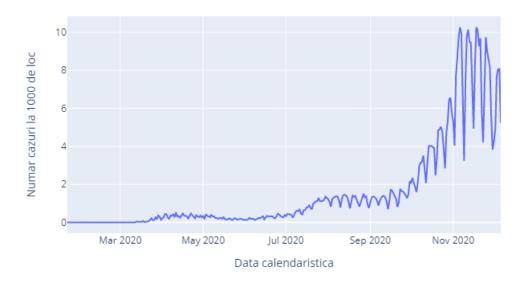


\*\* Evolutia numarului de cazuri raportat la zile la 1000 de loc in Romania \*\*

```
[7]: romania = romania.diff().fillna(romania[0])/1000
splot = Figure()
splot.add_trace(Scatter(x=romania.index, y=romania, name='confirmate'))
splot.update_layout(xaxis_title='Data calendaristica', yaxis_title='Numar

→cazuri la 1000 de loc', title='Cazuri in Romania pe zile')
splot.show()
```

## Cazuri in Romania pe zile



## 0.1.1 Variabile depedente si independente ale setului de date

- Fiecare zi in parte depinde de cele din trecut. In functie de precizia de predictie numarul de variabile indepedente de care depinde numarul de cazuri in ziua d variaza intre 1 zi si 320 de zile (sau numarul total de zile pentru care cunosc date)
- Daca marimea ferestrei (numarul de variabile indepedente) este prea mare atunci predictia nu mai este perfecta, modelul AI invata mai putin si prost. Acest numar de variabile trebuie sa fie mic, dar nici prea mic deoarece nu are destule informatii pentru o noua predictie
- Variabila depedenta este variabila care vreau sa o prezic (numarul de cazuri viitoare in ziua d raportate la cele dinainte)

### [8]: !pip install statsmodels

```
Requirement already satisfied: statsmodels in c:\programdata\anaconda3\envs\tensorflow\lib\site-packages (0.12.1)
Requirement already satisfied: scipy>=1.1 in c:\programdata\anaconda3\envs\tensorflow\lib\site-packages (from statsmodels) (1.4.1)
Requirement already satisfied: pandas>=0.21 in c:\programdata\anaconda3\envs\tensorflow\lib\site-packages (from statsmodels) (1.2.0)
Requirement already satisfied: numpy>=1.15 in c:\programdata\anaconda3\envs\tensorflow\lib\site-packages (from statsmodels) (1.18.5)
```

```
Requirement already satisfied: patsy>=0.5 in c:\programdata\anaconda3\envs\tensorflow\lib\site-packages (from statsmodels) (0.5.1)

Requirement already satisfied: python-dateutil>=2.7.3 in c:\programdata\anaconda3\envs\tensorflow\lib\site-packages (from pandas>=0.21->statsmodels) (2.8.1)

Requirement already satisfied: pytz>=2017.3 in c:\programdata\anaconda3\envs\tensorflow\lib\site-packages (from pandas>=0.21->statsmodels) (2019.3)

Requirement already satisfied: six in c:\programdata\anaconda3\envs\tensorflow\lib\site-packages (from patsy>=0.5->statsmodels) (1.15.0)
```

# 0.1.2 Se va incerca prezicerea datelor folosind modelul statistic ARIMA (Autoregressive Moving Avarage).

ARIMA este un model de prezicere statistic, adesea folosit pe serii de timp financiare (care prezinta evolutia in timp a valorii unei monede, gen Euro in raport cu alta, gen RON). ARIMA vine de la Autoregressive Integrated Moving Avarage.

Modelul autoregressive AR(1) este definit matematic ca fiind suma ponderata a zilelor precedente de care depinde functional ziua curenta. \* Formula matematica AR(n) =>  $y_t = c + \sum_{i=1}^n \beta_i * y_{t-i} + \epsilon_t$ , unde n este numarul de variabile de care depinde  $y_t$ ,  $\epsilon_t$  sunt factorii aleatorii (white noise), si  $\beta_i$  sunt parametrii modelului

Modelul moving avarage MA(1) este definit matematic ca fiind media aritmetica dintre momentele de timp anterioare, 1 este lungimea ferestrei in functie de care se calculeaza mediile \* Formula matematica MA(n) =>  $avg(y_t) = c + \frac{1}{n} * \sum_{i=1}^{n} \theta_i * y_{t-i}$  unde n este numarul de zile pe care se calculeaza media,  $y_{t-i}$  sunt valorile din zilele precedente, c este o constanta si  $\theta_i$  sunt parametrii modelului

Modelul integrated I(1) este acea parte din ARIMA care se ocupa cu reducerea seriei la una stationara, parametrii statistici raman constanti in timp, partea sezoniera si de trend fiind eliminate \* Formula matematica I(n) =>  $y_t = y_t - y_{t-n}$  unde n este lungimea intervalului asupra caruia i se aplica integrarea (nu are legatura cu integralele din analiza ci mai mult o derivata a functiei y(t))

Formula ARMA(p,q) de prezicere a lui  $y_t$  in final este  $y_t = \sum_{i=1}^p \beta_i * y_{t-i} + \frac{1}{q} * \sum_{i=1}^q \theta_i * y_{t-i} + \epsilon_t + c$ 

Testul statistic pentru a stabili o serie de timp daca este stationara este cea a lui Dickey-Fuller care spune ca daca: \* Media aritmetica este constanta in timp \* Abaterea standard este constanta in timp \* Seria nu variaza ciclic sau sezonier

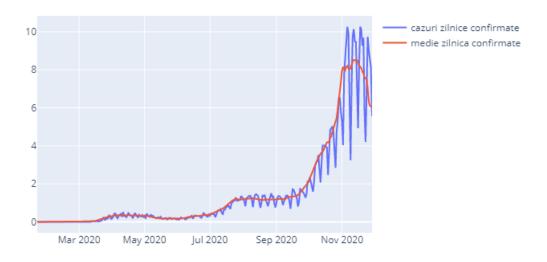
Atunci seria de timp este stationara

Testul calculeaza un parametru p care daca este mai mare ca 0.05 premisa cum ca seria este stationara este invalidata altfel aceasta este validata, deci seria este stationara.

```
[9]: def MA(data, nrZile):
    ma = []
    for i in range(0, len(data)-nrZile, 1):
        ma.append(np.mean(data[i:i+nrZile].values))
```

```
return ma
ma_romania = pd.Series(MA(romania, 7))
```

## Cazuri in Romania pe zile



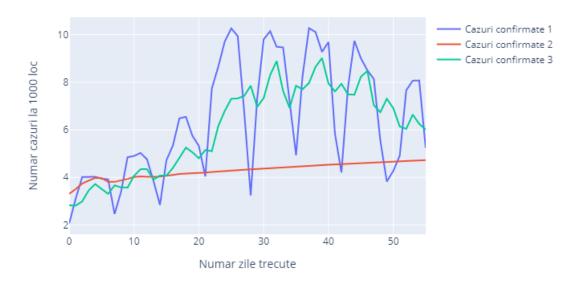
## 0.2 Comparatii intre metodele de prezicere existente

In continuare se vor prezenta 3 metode de prezicere a unei serii. O metoda implementata folosind RNA si Keras, una folosind modelul statistic ARIMA (din statsmodels) si una implementata de cei de la Facebook (Prophet)

Se vor determina si compara valorile fiecarui loss calculate folosind Rooted\_Mean\_Squared\_Error a carei formule matematice este: -  $loss = \sqrt{\frac{1}{n}\sum_{i=1}^{n}{(\hat{y}_i - y_i)^2}}$  - modelul cel mai sigur este cel al carui RMSE este cel mai mic - datele cunsocute sunt date foarte volatile, deci prezicerile nu vor putea fi cele mai sigure

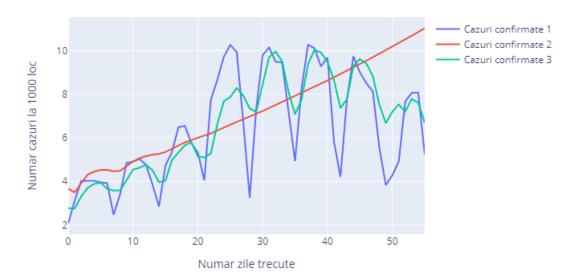
[11]:

[13]: covid19.plot(serieses=[asteptat, prezis, redresat])

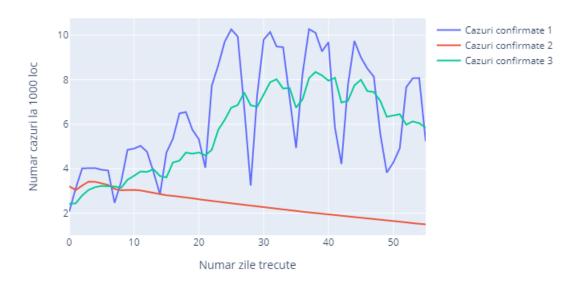


```
[14]: date['Denumire'].append('Retea Artificiala 1')
  date['NrStraturi'].append(1)
  date['NrNeuroni_1'].append(256)
```

```
date['NrNeuroni_2'].append('NaN')
      date['NrNeuroni_3'].append('NaN')
      date['ARIMA_P'].append(7)
      date['ARIMA_Q'].append('NaN')
      date['Loss'].append('%.5f' % np.sqrt(mean_squared_error(redresat, asteptat)))
      date['MovingWindowLoss'].append('%.5f' % np.sqrt(mean_squared_error(prezis,__
       →asteptat)))
[15]: covid19 = Covid19ANN()
      covid19.select('Unknown', 'Romania').build(window=7, predictions=56, dropout=0.
      \rightarrow2, layers=[128, 32], verbose=0)
      covid19.train(epochs=10, verbose=0)
      redresat, prezis, asteptat = covid19.test(window=7, predictions=56)
     (313, 1, 7) (313, 1)
     Scor pe setul de testare (RMSE): 0.136044720863225
     Testare cu fereastra deplasabila
     Scor pe setul de testare (RMSE): 0.2375812977552414
[16]: covid19.plot(serieses=[asteptat, prezis, redresat])
```



```
[17]: date['Denumire'].append('Retea Artificiala 2')
      date['NrStraturi'].append(1)
      date['NrNeuroni_1'].append(128)
      date['NrNeuroni_2'].append(32)
      date['NrNeuroni_3'].append('NaN')
      date['ARIMA_P'].append(7)
      date['ARIMA_Q'].append('NaN')
      date['Loss'].append('%.5f' % np.sqrt(mean_squared_error(redresat, asteptat)))
      date['MovingWindowLoss'].append('%.5f' % np.sqrt(mean_squared_error(prezis,__
       →asteptat)))
[18]: covid19 = Covid19ANN()
      covid19.select('Unknown', 'Romania').build(window=7, predictions=56, dropout=0.
      \rightarrow2, layers=[128, 32, 16], verbose=0)
      covid19.train(epochs=10, verbose=0)
      redresat, prezis, asteptat = covid19.test(window=7, predictions=56)
     (313, 1, 7) (313, 1)
     Scor pe setul de testare (RMSE): 0.16875167731051965
     Testare cu fereastra deplasabila
     Scor pe setul de testare (RMSE): 0.474637895822525
[19]: covid19.plot(serieses=[asteptat, prezis, redresat])
```



```
[20]: date['Denumire'].append('Retea Artificiala 3')
     date['NrStraturi'].append(1)
     date['NrNeuroni_1'].append(128)
     date['NrNeuroni_2'].append(32)
     date['NrNeuroni_3'].append(16)
     date['ARIMA_P'].append(7)
     date['ARIMA_Q'].append('NaN')
     date['Loss'].append('%.5f' % np.sqrt(mean_squared_error(redresat, asteptat)))
     date['MovingWindowLoss'].append('%.5f' % np.sqrt(mean_squared_error(prezis,__
      →asteptat)))
[21]: covid19 = Covid19ARIMA()
     covid19.select('Unknown', 'Romania').fit(ar=3, ma=4).summary()
[21]: <class 'statsmodels.iolib.summary.Summary'>
                                     SARIMAX Results
     Dep. Variable:
                        ('Unknown', 'Romania')
                                               No. Observations:
     292
     Model:
                               ARIMA(3, 1, 4)
                                                Log Likelihood
     -75.650
     Date:
                             Wed, 27 Jan 2021
                                                AIC
     167.301
     Time:
                                     12:26:07
                                                BIC
     196.687
     Sample:
                                   01-22-2020
                                               HQIC
     179.073
                                 - 11-08-2020
     Covariance Type:
                                          opg
     ______
                                                    P>|z|
                                                               Γ0.025
                                                                           0.9751
                      coef
                             std err
                    0.4289
                                                    0.046
     ar.L1
                               0.215
                                          1.992
                                                                0.007
                                                                           0.851
     ar.L2
                    0.0045
                               0.288
                                                    0.987
                                                                           0.568
                                         0.016
                                                               -0.559
     ar.L3
                               0.225
                   -0.8051
                                         -3.574
                                                    0.000
                                                               -1.247
                                                                           -0.364
     ma.L1
                   -0.6185
                               0.214
                                         -2.887
                                                    0.004
                                                               -1.038
                                                                           -0.199
     ma.L2
                    0.1023
                               0.305
                                          0.335
                                                    0.737
                                                               -0.495
                                                                           0.700
     ma.L3
                    0.7665
                               0.277
                                          2.772
                                                    0.006
                                                                0.224
                                                                            1.308
     ma.L4
                   -0.4146
                               0.081
                                         -5.149
                                                    0.000
                                                               -0.572
                                                                           -0.257
     sigma2
                    0.0958
                               0.003
                                         29.605
                                                    0.000
                                                                0.089
                                                                           0.102
     Ljung-Box (L1) (Q):
                                          1.87
                                                 Jarque-Bera (JB):
```

25596.16

Prob(Q): 0.17 Prob(JB):

0.00

Heteroskedasticity (H): 35.20 Skew:

4.58

Prob(H) (two-sided): 0.00 Kurtosis:

48.02

\_\_\_\_\_\_

===

## Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

11 11 11

[22]: [history, forecast] = covid19.predict(testing=True)

Scor model (RMSE): 1.608869159501195

[23]: covid19.plot(serieses=[history, forecast])

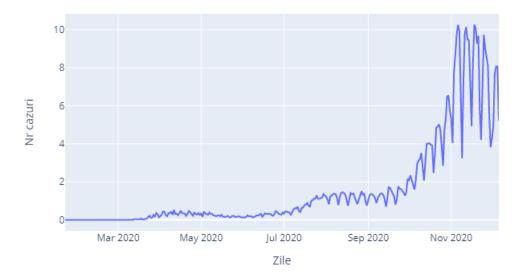


```
[24]: date['Denumire'].append('Model ARIMA')
  date['NrStraturi'].append('NaN')
  date['NrNeuroni_1'].append('NaN')
```

```
date['NrNeuroni_2'].append('NaN')
date['NrNeuroni_3'].append('NaN')
date['ARIMA_P'].append(3)
date['ARIMA_Q'].append(4)
date['Loss'].append('%.5f' % np.sqrt(mean_squared_error(forecast, history)))
date['MovingWindowLoss'].append('NaN')
```

!conda install -y -c conda-forge fbprophet

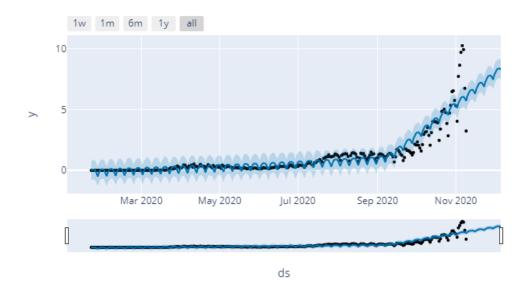
## Cazuri confirmate zilnice la 1000 loc



```
[27]: model = Prophet(daily_seasonality=False, yearly_seasonality=False)
    nrTotal = len(romania['ds'])
    test = romania.loc[nrTotal-28:,]
    train = romania.loc[:nrTotal-28,]
    model.fit(train)
    future = model.make_future_dataframe(periods=27)
    forecast = model.predict(future)
    forecast[['ds', 'yhat', 'yhat_lower', 'yhat_upper']].tail()
    loss = np.sqrt(mean_squared_error(romania['y'], forecast['yhat']))
    print(f'Scor predictie (RMSE): {loss}')
```

Scor predictie (RMSE): 0.8963779230583288

```
[28]: from fbprophet.plot import plot_plotly plot_plotly(model, forecast)
```



```
[29]: date['Denumire'].append('Model Facebook Prophet')
  date['NrStraturi'].append('NaN')
  date['NrNeuroni_1'].append('NaN')
  date['NrNeuroni_2'].append('NaN')
  date['NrNeuroni_3'].append('NaN')
  date['ARIMA_P'].append('NaN')
  date['ARIMA_Q'].append('NaN')
```

```
date['Loss'].append('%.5f' % np.sqrt(mean_squared_error(romania['y'],

→forecast['yhat'])))
date['MovingWindowLoss'].append('NaN')
```

NaN

## [30]: pd.DataFrame(date)

4

 ${\tt NaN}$ 

NaN 0.89638

[30]:			Γ	enumire	NrStraturi	NrNeuroni_1	NrNeuroni_2	NrNeuroni_3	\
	0	Ret	ea Artifi	ciala 1	1	256	NaN	NaN	
	1	Ret	ea Artifi	ciala 2	1	128	32	NaN	
	2	Ret	ea Artifi	ciala 3	1	128	32	16	
	3		Mode	al ARIMA	NaN	NaN	NaN	NaN	
	4	Model	Facebook	Prophet	NaN	NaN	NaN	NaN	
		ARIMA_P	ARIMA_Q	Loss	MovingWin	dowLoss			
	0	7	NaN	1.70433		3.09772			
	1	7	NaN	1.39704	:	2.43972			
	2	7	NaN	1.73291		4.87406			
	3	3	4	1.60887		NaN			